INSTITUTO POLITÉCNICO DO CÁVADO E DO AVE

Escola Superior de Tecnologia
Licenciatura em Engenharia de Sistemas Informáticos

TRABALHO PRÁTICO 1

Pipeline ETL para análise de performance e campanhas de segurança da gama BMW M

Autor	Gonçalo Correia — n.º 22840
Unidade curricular	Integração de Sistemas de Informação
Ano letivo	2026/2027
Data	Outubro de 2026

Relatório técnico revisto

Resumo

Este trabalho apresenta uma pipeline ETL desenvolvida em Pentaho Data Integration 10.2 para integrar um ficheiro local de especificações de veículos BMW M com contagens de campanhas de segurança consultadas na API REST da National Highway Traffic Safety Administration (NHTSA). A solução inclui validação e quarentena de dados, cálculo de indicadores mecânicos, rastreabilidade das consultas HTTP, consolidação em 18 campos, persistência em PostgreSQL e exportação em JSON e XML.

A revisão final confirmou 29 registos na fonte, um registo com peso omisso e 28 veículos mecanicamente válidos. Não existem duplicados na fonte atual segundo a chave (`make, model, year`). A execução revista de T2 obteve 15 respostas HTTP 200 válidas e 13 respostas HTTP 400; estas últimas são representadas por contagens nulas, evitando que ausência de resposta válida seja confundida com zero campanhas.

Palavras-chave: ETL, Pentaho PDI, Kettle, PostgreSQL, REST, NHTSA, qualidade de dados.

1. Enquadramento

O trabalho foi realizado no âmbito da unidade curricular de Integração de Sistemas de Informação. O objetivo pedagógico consiste em demonstrar recolha, transformação, integração, persistência, orquestração e exportação de dados heterogéneos através de um fluxo reproduzível.

O domínio escolhido é a gama BMW M. O projeto cruza atributos técnicos — potência, peso, cilindrada e aceleração — com o número de campanhas devolvido pela NHTSA para uma combinação de marca, modelo genérico e ano.

2. Problema e objetivos

As duas fontes têm natureza e granularidade diferentes:

- `data/raw/specs.csv` contém especificações por variante, por exemplo `M3 E46 CSL`.
- A API NHTSA é consultada com `make`, prefixo genérico do modelo e `modelYear`, por exemplo `BMW`, `M3`, `2003`.

O problema de integração consiste em limpar a fonte local, impedir cálculos sobre valores inválidos, reduzir a designação da variante à chave aceite pela consulta, distinguir respostas válidas de falhas HTTP e produzir saídas coerentes sem atribuir à variante uma especificidade que a API não demonstra.

Os objetivos técnicos são:

- preservar a arquitetura T1 → T2 → T3 → T4 → T5;
- manter os dados rejeitados numa área de quarentena;
- calcular indicadores mecânicos verificáveis;
- conservar nulos relevantes, como o preço do M5 E34;
- impedir que erros HTTP ou JSON sejam convertidos silenciosamente em zero;
- evitar credenciais reutilizáveis nos ficheiros versionados;
- produzir CSV, PostgreSQL, JSON e XML;
- disponibilizar testes automáticos reproduzíveis.

3. Metodologia e proveniência dos dados

3.1. Especificações locais

O ficheiro `data/raw/specs.csv` é uma fonte fornecida no próprio projeto. Contém 29 registos entre 1985 e 2024. Não existe, no repositório, documentação que associe cada valor histórico a uma fonte BMW ou

publicação independente. Assim, estes valores são tratados como dados de entrada do exercício e não como especificações oficialmente verificadas.

O ficheiro `data/raw/series_lookup.csv` é uma tabela de correspondência criada para a transformação. Mapeia `M2`, `M3`, `M4`, `M5`, `M6` e `M8` para uma designação de série e um tipo de carroçaria agregado.

3.2. Dados NHTSA

A NHTSA disponibiliza informação oficial sobre campanhas de segurança nos Estados Unidos. T2 usa o endpoint:

```
https://api.nhtsa.gov/recalls/recallsByVehicle
    ?make=<make>
    &model=<model_prefix>
    &modelYear=<year>
```

Os três parâmetros enviados são:

- `make`: marca normalizada, neste caso `BMW`;
- `model`: prefixo genérico extraído por `^(M\d)\b.*`, como `M3`;
- `modelYear`: ano presente na fonte local.

Esta granularidade é marca/modelo genérico/ano. Uma resposta para `BMW M3 2003` pode abranger a família identificada pela NHTSA, mas não prova que todas as campanhas se aplicam especificamente ao `M3 E46 CSL`. Também não representa uma avaliação global de fiabilidade mecânica.

3.3. Critério de validade da resposta

Uma contagem só é aceite quando:

- o estado HTTP pertence ao intervalo 200–299;
- o corpo é JSON válido;
- existe a propriedade `Count`;
- `Count` é um inteiro não negativo.

`Count = 0` é guardado como zero apenas quando satisfaz estas condições. Erros HTTP, JSON inválido e `Count` ausente ou inválido originam contagem nula e um estado explícito em `nhtsa_recalls.csv`. Um timeout ou erro de transporte no REST Client continua a produzir falha da transformação e é propagado pelo job.

4. Arquitetura da solução

```
flowchart LR
    RAW[specs.csv + series_lookup.csv] --> T1[T1: limpar e validar]
    T1 --> CLEAN[specs_limpas.csv]
    T1 --> QUAR[rejeitados_specs.csv]
    CLEAN --> T2[T2: consultar NHTSA]
    API[(API NHTSA)] --> T2
    T2 --> REC[nhtsa_recalls.csv]
    CLEAN --> T3[T3: consolidar]
    REC --> T3
    T3 --> FINAL[bmw_m_performance_fiabilidade.csv]
    FINAL --> T4[T4: Insert/Update]
    T4 --> PG[(PostgreSQL)]
    PG --> T5[T5: exportar]
    T5 --> JSON[catálogo JSON]
    T5 --> XML[resumo XML]
```

Os caminhos dos ficheiros Kettle são relativos a `${Internal.Entry.Current.Directory}`, reduzindo dependências da localização absoluta do repositório.

5. Transformações

5.1. T1 — extração, limpeza e enriquecimento

T1 executa os seguintes passos:

- leitura dos dois CSV de entrada;
- `trim` e normalização de `make`;
- extração de `versao` por expressão regular e preenchimento com `Base` quando não existe edição identificada;
- validação de peso, potência, cilindrada e ano;
- encaminhamento de inválidos para quarentena;
- extração de `model_prefix`;
- ordenação e deduplicação pela chave `(make, model, year)`;
- cálculo dos indicadores mecânicos;
- `Stream Lookup` para série e carroçaria;
- validação da correspondência no lookup e exportação.

As fórmulas são:

```
peso_ton          = weight_kg / 1000
litros            = engine_cc / 1000
hp_por_tonelada   = engine_hp / peso_ton
hp_por_litro      = engine_hp / litros
```

O M3 E92 GTS (2010) permanece em `data/staging/rejeitados_specs.csv` por ter `weight_kg` omisso. Não foi estimado um peso.

Não foi removido qualquer duplicado da fonte atual: os 29 registos de `specs.csv` já são únicos. `Sort Rows` e `Unique Rows` foram mantidos para demonstrar e garantir a regra caso surjam duplicados futuros.

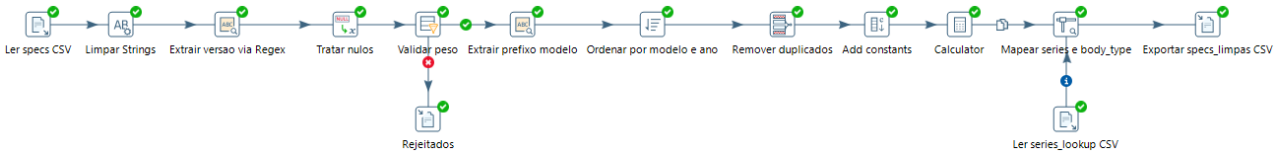


Figura 1 — Captura existente do fluxo T1. A versão final acrescenta validações ao filtro e ao resultado do lookup; a configuração versionada no `.ktr` é a referência atual.

Execution Results

Logging | Execution History | Step Metrics | Performance Graph | Metrics | Preview data

#	Nome do step	Copia nr	Lidos	escritos	Entrada	Sa◆da	Atualizados	Rejected	Erros	Ativo	Tempo	Velocidade (r/s)	Pri/ent/sai
1	Ler specs CSV	0	0	29	30	0	0	0	0	Finished	0.0s	1.304	-
2	Limpar Strings	0	29	29	0	0	0	0	0	Finished	0.0s	1.036	-
3	Extrair versao via Regex	0	29	29	0	0	0	0	0	Finished	0.0s	630	-
4	Ler series_lookup CSV	0	0	6	7	0	0	0	0	Finished	0.0s	368	-
5	Tratar nulos	0	29	29	0	0	0	0	0	Finished	0.1s	483	-
6	Validar peso	0	29	29	0	0	0	0	0	Finished	0.1s	392	-
7	Extrair prefixo modelo	0	28	28	0	0	0	0	0	Finished	0.1s	311	-
8	Ordenar por modelo e ano	0	28	28	0	0	0	0	0	Finished	0.1s	228	-
9	Remover duplicados	0	28	28	0	0	0	0	0	Finished	0.2s	183	-
1..	Add constants	0	28	28	0	0	0	0	0	Finished	0.2s	167	-
1..	Calculator	0	28	28	0	0	0	0	0	Finished	0.2s	140	-
1..	Rejeitados	0	1	1	0	2	0	0	0	Finished	0.1s	19	-
1..	Mapear series e body_type	0	34	28	0	0	0	0	0	Finished	0.2s	156	-
1..	Exportar specs_limpas CSV	0	28	28	0	29	0	0	0	Finished	0.2s	117	-

Figura 2 — Evidência anterior de 29 registos lidos, um rejeitado e 28 exportados; as mesmas contagens foram reproduzidas na revisão.

5.2. T2 — extração NHTSA e controlo de erros

T2 reduz os 28 veículos às combinações únicas `(make, model_prefix, year)`, constrói o URL com `encodeURIComponent` e executa pedidos GET através do `REST Client`.

Após cada resposta, `Validar resposta NHTSA` analisa `http_status` e o corpo JSON. O fluxo distingue `OK`, `OK_ZERO`, `ERRO_HTTP_<código>`, `JSON_INVALIDO`, `COUNT_AUSENTE` e `COUNT_INVALIDO`. As situações inválidas são registadas com marca, modelo, ano, URL, estado HTTP e categoria, sem utilizadores ou passwords.

O ficheiro intermédio inclui seis campos:

```
make, model, year, nhtsa_recalls_count, nhtsa_query_status, nhtsa_http_status
```

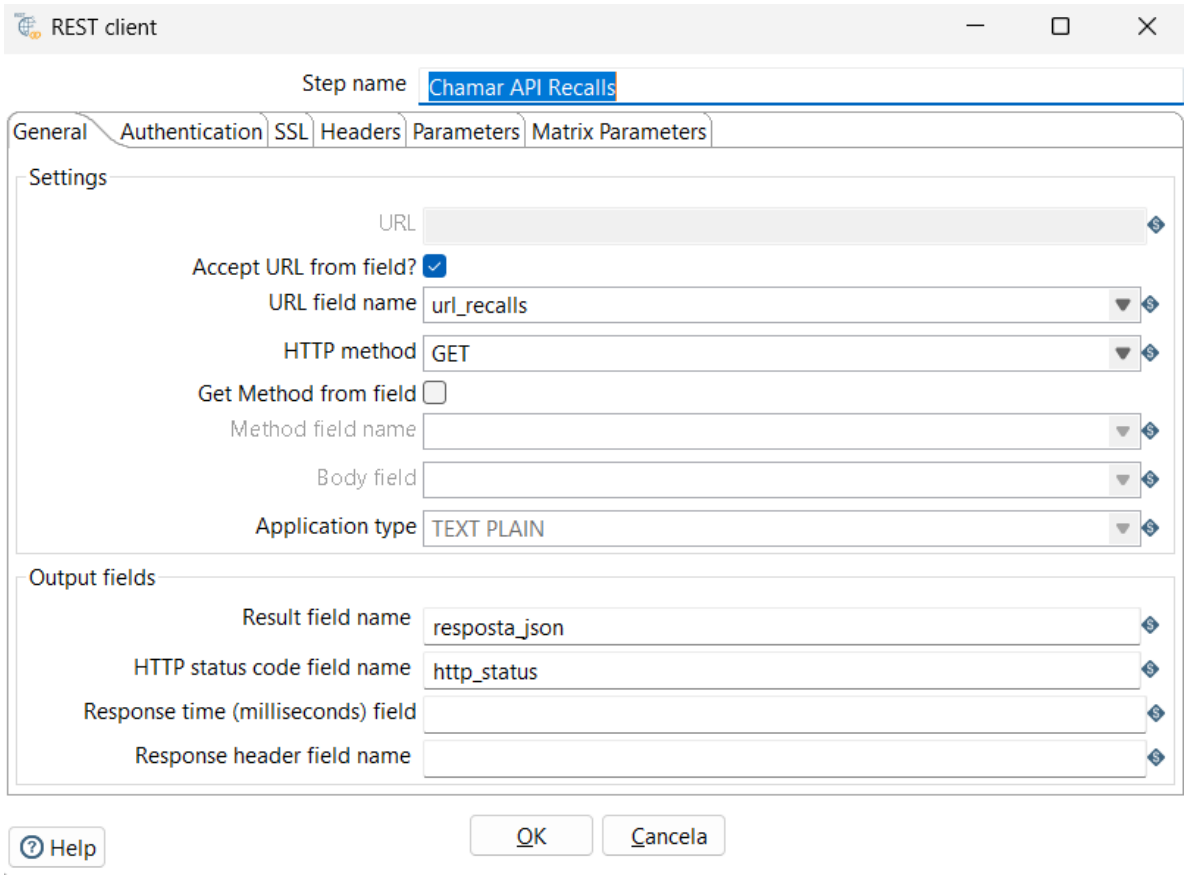


Figura 3 — Configuração do REST Client. A validação explícita introduzida depois deste step é descrita pela configuração XML atual e deve receber uma captura nova antes da entrega.

5.3. T3 — consolidação e indicador exploratório

T3 ordena as especificações e os resultados NHTSA e executa um `LEFT OUTER JOIN` por marca, prefixo/modelo e ano. Os campos de rastreabilidade de T2 são usados antes da consolidação e removidos para preservar o esquema final de 18 campos.

A versão revista não contém o antigo step que substituía `nhtsa_recalls_count = NULL` por zero. Consequentemente, uma consulta inválida produz `nhtsa_recalls_count` e `recalls_por_100hp` nulos.

O indicador é calculado apenas quando existe contagem válida:

```
recalls_por_100hp = nhtsa_recalls_count / engine_hp × 100
```

Este rácio normaliza uma contagem de campanhas por potência. É útil para demonstrar transformação e agregação, mas não tem validação científica como medida de fiabilidade, não controla volume de produção, quilometragem, mercado, gravidade, duração de exposição ou componentes afetados.

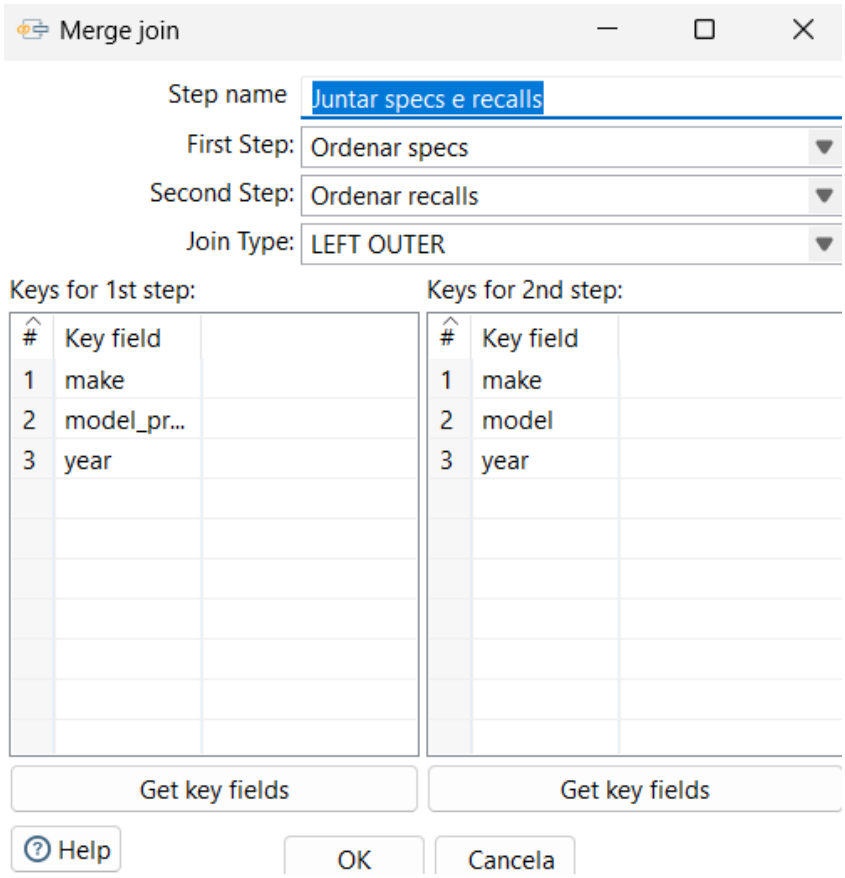


Figura 4 — Configuração do `LEFT OUTER JOIN` de T3.

5.4. T4 — carga PostgreSQL

O DDL cria a tabela `bmw_m_performance_fiabilidade` com chave primária técnica, chave única (`make, model, year`), tipos `NUMERIC` para valores decimais e restrições para ano, peso, potência, cilindrada e contagens não negativas.

`price_usd`, `nhtsa_recalls_count` e `recalls_por_100hp` aceitam nulo. Esta opção preserva, respetivamente, o preço omisso do M5 E34 e a ausência de resposta NHTSA válida.

A carga usa o step `Insert/Update`, com procura pela chave (`make, model, year`) e atualização dos restantes 15 campos. Esta solução evita o `TRUNCATE` anteriormente configurado. Contudo, não equivale a uma substituição transacional integral: uma interrupção pode deixar apenas parte das linhas atualizada e uma linha removida da fonte não é eliminada automaticamente.

As propriedades da ligação são resolvidas através de `PGHOST`, `PGPORT`, `PGDATABASE`, `PGUSER` e `PGPASSWORD`. Nenhuma password reutilizável permanece nos `.ktr`.

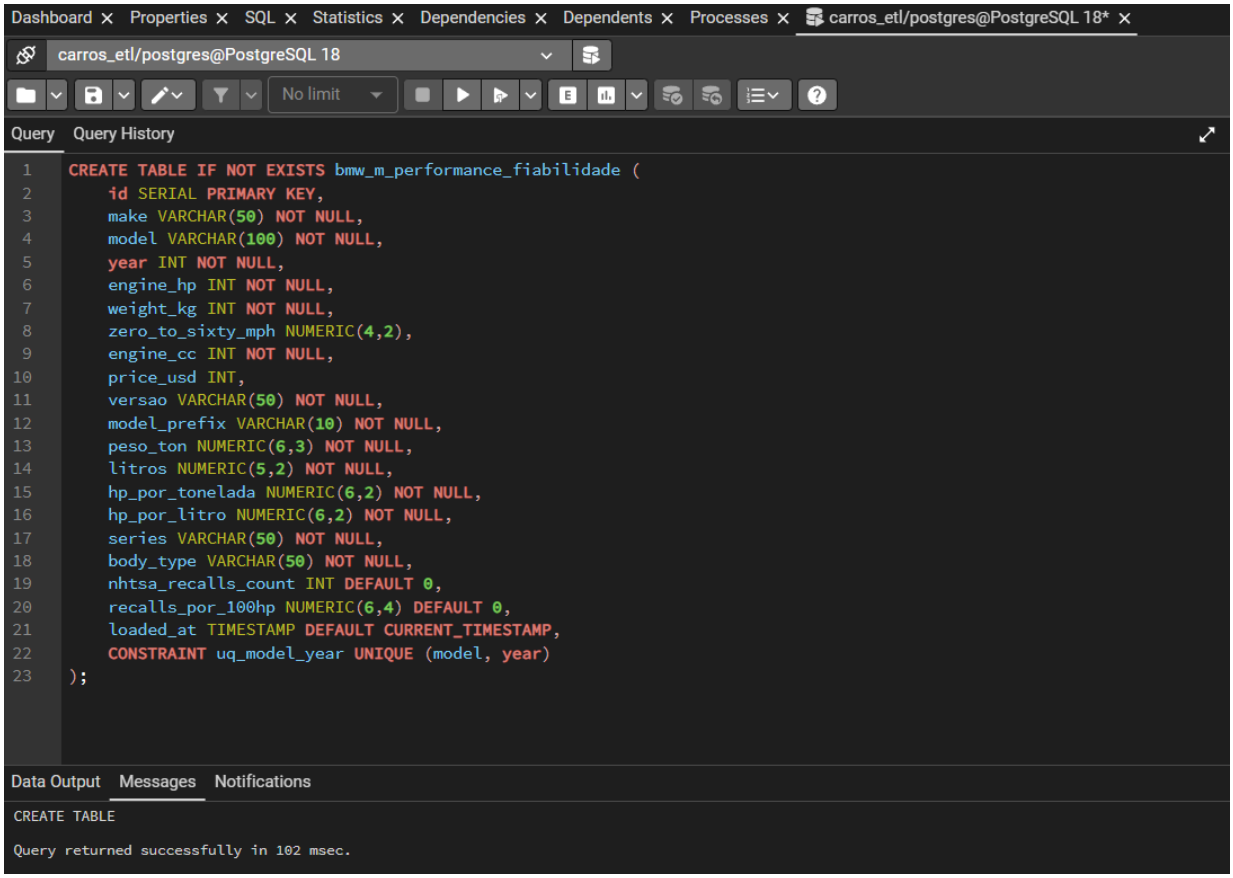


Figura 5 — Evidência existente da preparação do esquema. A revisão acrescentou restrições ao DDL; deve ser capturada novamente após instalação limpa.

5.5. T5 — exportação JSON e XML

T5 lê a tabela ordenada por série e ano e copia o fluxo para dois ramos:

- `JsonOutput`: catálogo de 28 objetos e 18 atributos;
- `GroupBy` + `XMLOutput`: resumo das seis séries.

A perda de casas decimais em `media_hp` foi corrigida sem alterar o tipo de `engine_hp` no catálogo. A consulta cria o campo auxiliar decimal:

```
CAST(engine_hp AS NUMERIC(10,2)) AS engine_hp_agregacao
```

O `GroupBy` calcula `AVERAGE(engine_hp_agregacao)` e o XML usa o formato `0.00`. O resumo inclui ainda `modelos_com_resposta_nhtsa`, calculado a partir da presença de uma contagem válida. Os dois steps de saída estão configurados para não abrir um ficheiro novo durante a inicialização: se a leitura PostgreSQL falhar antes de emitir linhas, os relatórios existentes não são substituídos por ficheiros vazios.

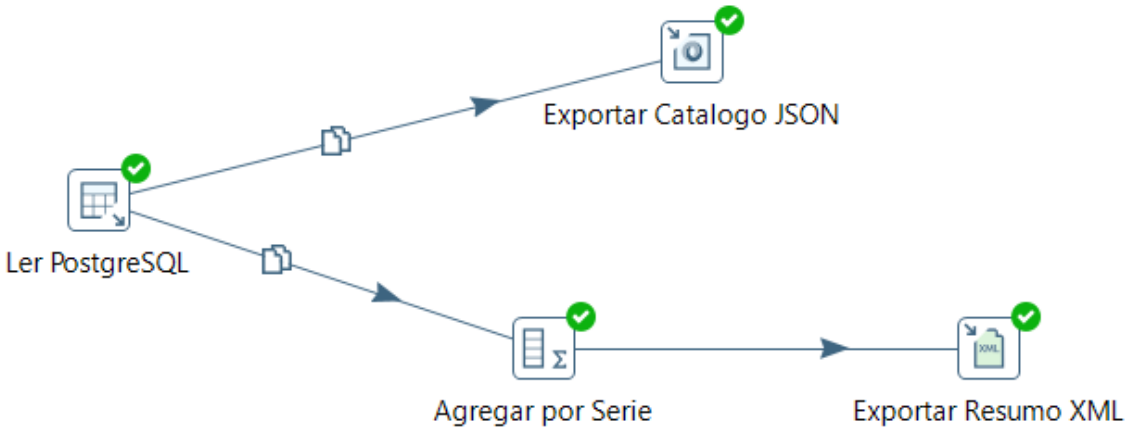


Figura 6 — Captura anterior do fluxo T5. A versão final mantém a topologia e acrescenta campos auxiliares; é necessária uma nova captura da configuração final.

6. Job de orquestração

`kettle/jobs/J_main.kjb` executa sequencialmente:

```
START → T1 → T2 → T3 → T4 → T5 → Sucesso ETL
```

Cada transformação tem um hop de falha para `Abortar por Erro`. Assim, um timeout do REST Client, erro de leitura, falha de cálculo ou erro de base de dados impede a continuação normal.

O job não deve ser descrito como uma transação atómica entre ficheiros, API e PostgreSQL: estes sistemas não partilham uma transação distribuída. O mecanismo implementado é controlo sequencial e paragem perante erro.

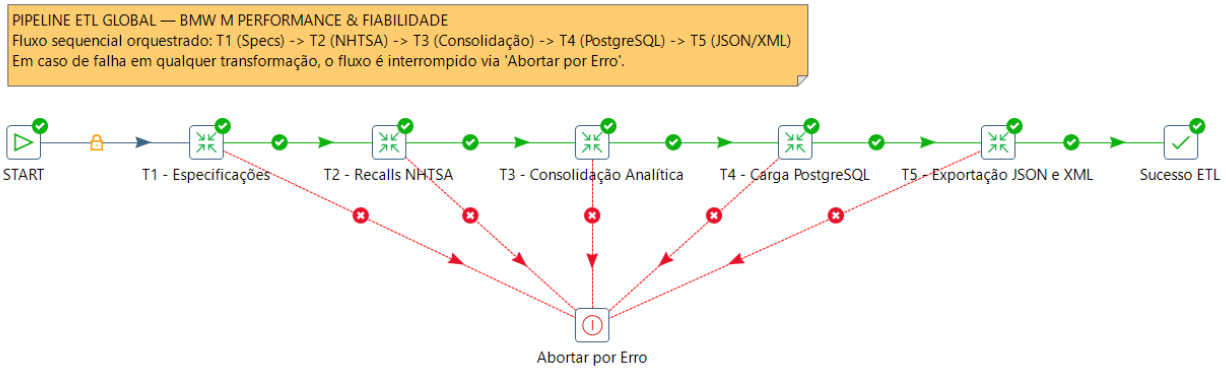


Figura 7 — Job de orquestração T1 a T5 e caminhos de erro.

7. Resultados verificados

7.1. Qualidade e volume

Verificação	Resultado
Registos em `specs.csv`	29
Duplicados na chave `(make, model, year)`	0
Registos rejeitados por T1	1
Veículos válidos	28

Verificação	Resultado
Séries	6
Respostas NHTSA HTTP 200 válidas na execução revista	15
Respostas NHTSA HTTP 400 na execução revista	13

Os estados da API são mutáveis. Estes números descrevem a execução de revisão efetuada em 20 de outubro de 2026 e não devem ser assumidos como permanentes.

7.2. Resumo por série

Série	Modelos	Respostas NHTSA válidas	Potência média (hp)	Total de campanhas nas respostas válidas	Média exploratória de recalls/100 hp
Série 2 M	4	4	422.50	5	0.2925
Série 3 M	9	6	395.00	22	0.9700
Série 4 M	4	3	487.75	7	0.5000
Série 5 M	8	1	503.75	1	0.1600
Série 6 M	2	0	533.50	n/d	n/d
Série 8 M	1	1	600.00	1	0.1700

As médias NHTSA usam apenas linhas com resposta válida. Por isso, não são diretamente comparáveis quando a cobertura é muito diferente. Em particular, não existe base para concluir que a Série 6 tem zero campanhas ou maior fiabilidade: nesta execução não houve resposta HTTP válida para os dois anos consultados.

7.3. Interpretação prudente

Os resultados demonstram a integração técnica e o cálculo dos indicadores. Não sustentam conclusões causais sobre sobrealimentação, qualidade de construção, robustez de motores ou fiabilidade geral. Uma campanha de segurança pode incidir num componente partilhado e a consulta por prefixo não identifica automaticamente a variante concreta.

8. Testes e validação

Foi criada uma suite com Python `unittest`, sem dependências externas. Os 23 testes cobrem:

- leitura, estrutura e contagens dos CSV;
- presença dos 28 veículos e preservação do rejeitado;
- ausência de duplicados e teste com duplicado artificial;
- campos obrigatórios e intervalos;
- fórmulas mecânicas e de recalls;
- preço nulo do M5 E34;
- coerência CSV/JSON;
- agregações e precisão do XML;
- XML bem formado e hops Kettle existentes;
- configuração das validações T1/T2/T3/T4/T5;
- fixtures para zero válido, erro HTTP, timeout, JSON inválido e `Count` ausente/inválido.

T1, T2 e T3 foram executadas nesta revisão com PDI 10.2. T4, T5 e J_main ficaram pendentes por falta de uma instância PostgreSQL configurada e salvaguardada. O XML e JSON versionados foram alinhados deterministicamente com o CSV consolidado e validados pelos testes; não são apresentados como resultado de uma nova execução de T5.

9. Limitações

- Falta de proveniência externa das especificações do CSV.
- Cobertura da NHTSA centrada no mercado dos EUA.
- Consulta por modelo genérico, sem confirmação por VIN ou variante.
- Estados e contagens da API sujeitos a alteração.
- Ausência de controlo por parque circulante, produção, quilometragem, gravidade ou tempo de exposição.
- Indicador `recalls_por_100hp` exploratório e não validado.
- Carga `Insert/Update` idempotente por chave, mas não atómica para todo o dataset.
- T4/T5/job final ainda por validar numa base preparada.
- Algumas capturas existentes antecedem as correções finais.
- Vídeo e QR Code ainda pendentes.

10. Vídeo demonstrativo e QR Code

> AÇÃO MANUAL NECESSÁRIA: gravar e publicar o vídeo demonstrativo com base em `docs/GUIAO_VIDEO.md`, confirmar acesso através de uma janela privada e só depois inserir nesta secção o URL real e o respetivo QR Code. Não existe atualmente um endereço de vídeo validado.

O ficheiro `docs/CHECKLIST_DEMONSTRACAO.md` contém os passos de preparação e validação.

11. Conclusão e trabalhos futuros

A pipeline implementa as operações essenciais de um processo ETL: ingestão de CSV, chamada REST, controlo de qualidade, quarentena, expressões regulares, deduplicação, lookup, junção, cálculo, carga relacional, exportação e orquestração. A revisão corrigiu a precisão da potência média, removeu a conversão indevida de respostas NHTSA inválidas em zero, reforçou as regras de T1 e retirou credenciais versionadas.

O projeto está tecnicamente mais próximo da entrega, mas a conclusão deve permanecer condicionada: ainda é necessário executar T4, T5 e o job completo numa base salvaguardada, atualizar as capturas afetadas e acrescentar o vídeo com QR Code real ao PDF técnico já gerado e revisto.

Como trabalhos futuros propõem-se:

- validar campanhas por VIN quando exista um identificador real e autorização para o usar;
- guardar data/hora, URL e categoria de cada consulta numa tabela de auditoria;
- introduzir repetição controlada com *backoff* para falhas transitórias;
- carregar primeiro para uma tabela temporária e efetuar uma troca transacional validada;
- documentar fontes primárias para cada especificação automóvel;
- executar testes de integração com PostgreSQL num ambiente descartável.

12. Referências

- National Highway Traffic Safety Administration. “NHTSA Datasets and APIs — Recalls”. Disponível em: https://www.nhtsa.gov/nhtsa-datasets-and-apis. Consultado em 20/10/2026.
- National Highway Traffic Safety Administration. “Resources Related to Investigations and Recalls”. Disponível em: https://www.nhtsa.gov/resources-investigations-recalls. Consultado em 20/10/2026.
- Hitachi Vantara. “Pentaho Data Integration 10.2”. Disponível em: https://docs.pentaho.com/pdia-data-integration/10.2-data-integration. Consultado em 20/10/2026.
- Hitachi Vantara. “REST Client — General tab”. Disponível em: https://docs.pentaho.com/pdia-data-integration/10.2-data-integration/pdi-transformation-steps-reference-overview/rest-client-step/options-rest-client/general-tab. Consultado em 20/10/2026.
- Hitachi Vantara. “Group By”. Disponível em: https://docs.pentaho.com/pdia-data-integration/10.2-data-integration/pdi-transformation-steps-reference-overview/group-by-landing-page-article. Consultado em 20/10/2026.
- Hitachi Vantara. “Use Command Line Tools to Run Transformations and Jobs”. Disponível em: https://docs.pentaho.com/pdia-data-integration/10.2-data-integration/advanced-topics-pentaho-data-integration-overview/use-command-line-tools-to-run-transformations-and-jobs. Consultado em 20/10/2026.
- PostgreSQL Global Development Group. “PostgreSQL 18 — CREATE TABLE”. Disponível em: https://www.postgresql.org/docs/current/sql-createtable.html. Consultado em 20/10/2026.